

L'Arène se mord la queue :

audit temporel, causal et structurel de la vulnérabilité
au style sur *Compar :IA* à travers la loi de Goodhart

Équipe hackathon Compar :IA × Dauphine PSL
Extension du travail de Simon Zilinskas (2026)

Juin 2026

Résumé

Les arènes d'évaluation de grands modèles de langage (LLM) reposent sur des préférences humaines pairwise. Lorsqu'un classement devient une cible institutionnelle, la loi de Goodhart prédit une dérive vers des *proxies* mesurables — format markdown, longueur, structure — au détriment de la qualité intrinsèque. Nous étendons l'analyse *style-controlled* de Zilinskas [2026] sur *Compar :IA*, arène francophone de la DINUM ($\approx 145\,000$ combats nettoyés, 89 modèles), selon six axes complémentaires : (i) dynamique temporelle de la diversité stylistique (R1/R1-bis) ; (ii) évolution mensuelle du *style premium* (R2bis) ; (iii) preuve causale par réécritures contrefactuelles et juges LLM (R3) ; (iv) ablation style *vs.* qualité déclarée et longueur (R5/R5bis) ; (v) endogénéité par tier de modèle (R6). La diversité *globale* augmente ($\beta = +0,057$ par mois en R1 brut, $p < 0,001$), mais R1-bis montre que, sur une **cohorte fixe** de 9 modèles présents ≥ 12 mois (dont Llama-3.3-70B et Llama-3.1-8B), la dispersion stylistique densifiée est **stable** ($\beta = -0,003$, $p = 0,71$) — compatible avec un *artefact de composition* de l'arène plutôt qu'une divergence stylistique réelle. Pas de dérive temporelle du premium (gras $-1,4$ points/mois). En revanche, la vulnérabilité au formatage est robuste : contrefactuels concis $\rightarrow 89\text{--}97\%$ de victoires, verbores $\rightarrow 21\text{--}27\%$; AUC prédictive du vote passe de 0,821 (qualité seule) à 0,862 (+ style) ; après contrôle qualité+longueur, le gras conserve $+14,5\%$ d'odds de victoire. Les modèles les mieux classés formatent davantage ($r = 0,57$ entre rating et score de format), excluant une simple stratégie de *gaming* par les modèles faibles. *Compar :IA* ne présente pas encore les symptômes d'effondrement d'un benchmark Goodhart, mais reste sensible au style — un risque à anticiper pour toute métrique devenue cible.

Mots-clés : évaluation LLM, arène pairwise, loi de Goodhart, style control, Bradley-Terry, inférence causale, Compar :IA.

1 Introduction

1.1 Contexte et enjeu

Compar :IA est une plateforme d'évaluation de LLM opérée par la Direction interministérielle du numérique (DINUM) et le ministère de la Culture [Termignon et al., 2026]. Deux modèles anonymes répondent au même prompt ; l'utilisateur choisit un gagnant ou déclare une égalité. Le classement agrégé informe la politique publique francophone en matière d'IA.

Ce mécanisme rejoint la famille des arènes pairwise popularisées par Chatbot Arena [Chiang et al., 2024, Zheng et al., 2023]. Le signal utilisateur mêle toutefois qualité perçue et heuristiques de surface : longueur, markdown, listes, gras [Zheng et al., 2023, Li et al., 2024].

1.2 Cadre Goodhart

La loi de Goodhart [Goodhart, 1975, Manheim and Garra-brant, 2018] stipule qu’une mesure utilisée comme cible cesse d’être une bonne mesure. Appliquée aux benchmarks, elle prévoit trois stades observables [Espeland and Sauder, 2016] : (i) convergence des participants vers les traits corrélés au score ; (ii) hausse du poids des proxies dans le score ; (iii) perte de pouvoir discriminant du benchmark.

Notre question centrale : *Compar :IA* présente-t-il déjà ces signaux, et dans quelle mesure le formatage influence-t-il les votes indépendamment de la qualité ?

1.3 Positionnement par rapport à Zilinskas (2026)

Zilinskas [2026] appliquent pour la première fois le *style control* à une arène non anglophone. Sur un instantané de 145 096 combats, ils estiment un modèle de Bradley-Terry [Bradley and Terry, 1952] où chaque feature de formatage entre linéairement :

$$\mathbb{P}(A \text{ bat } B) = \sigma \left(\beta_A - \beta_B + \sum_f \gamma_f \Delta f_{AB} \right), \quad (1)$$

avec $\Delta f_{AB} = f_A - f_B$ standardisé. Ils trouvent des premiums de +16–19 % par écart-type pour le gras, les listes et les en-têtes ; 76 modèles changent significativement de rang après correction FDR [Benjamini and Hochberg, 1995], mais la corrélation globale des classements reste élevée ($r = 0,976$).

Nous **prolongeons** ce travail sans le contredire, en ajoutant :

1. une dimension **temporelle** (R1, R1-bis, R2bis) absente du papier original ;
2. une dimension **causale** par contrefactuels (R3) ;
3. une décomposition **qualité / longueur / structure** (R5, R5bis) ;
4. une analyse d’**endogénéité** par tier de performance (R6).

1.4 Thèse empirique retenue

L’hypothèse initiale du hackathon — effondrement imminent et convergence stylistique — n’est *pas* confirmée par les données. La thèse retenue est plus nuancée :

Compar :IA ne montre pas encore les symptômes d’un benchmark en effondrement Goodhart, mais reste **vulnérable au style** — observationnellement (R5/R5bis/R6) et causalement (R3).

Le module prospectif R4 (forecast d’effondrement) a été abandonné faute de tendance à projeter.

1.5 Plan de l’article

La Section 2 décrit les données. La Section 3 détaille les méthodes et calculs. La Section 4 présente les résultats module par module. Les Sections 5–7 discutent les implications, limites et conclusions.

2 Données

2.1 Sources

Nous réutilisons le corpus nettoyé de Zilinskas [2026], publié sur HuggingFace (`ministere-culture/compari`). Après filtrage (paires identiques, doublons, combats sans texte visible pour modèles *reasoning*), il reste **145 096 combats** impliquant **89 modèles** avec ≥ 100 combats chacun, sur 16 mois (octobre 2024 – janvier 2026).

2.2 Variables observées

Pour chaque combat entre modèles A et B sur un prompt p :

- **Outcome** $y \in \{A, B, \text{tie}\}$;
- **Textes** de réponse r_A, r_B ;
- **Métadonnées** : date, mode d'arène (*random*, *custom*, etc.) ;
- **Attributs qualité déclarés** (sous-ensemble) : clarté, exactitude, utilité, etc., annotés post-vote par l'utilisateur.

2.3 Features stylistiques

Cinq features de surface sont extraites par expressions régulières sur r :

TABLE 1 – Features stylistiques (identiques à Zilinskas).

Feature	Description	Exemple
headers	lignes commençant par #	# Titre
lists	puces ou numérotations	- item, 1. item
bold	gras markdown	texte
code_blocks	blocs de code	"python ... "
emoji	caractères emoji Unicode	:smile:

Pour chaque feature f , on calcule un compte brut $f(r)$ puis, par combat, le différentiel $\Delta f = f(r_A) - f(r_B)$. Les versions standardisées Δf_z utilisent la moyenne et l'écart-type empiriques sur l'échantillon.

2.4 Features qualité et longueur (R5/R5bis)

Pour R5, nous agrégeons les attributs qualité déclarés en un score **quality_total** (somme des indicateurs binaires positifs par réponse). Pour R5bis, nous ajoutons $\Delta \log(1 + |r|)$ où $|r|$ est la longueur en caractères de la réponse assistant (proxy de verbosité, distinct des tokens HF).

2.5 Échantillons par module

TABLE 2 – Tailles d'échantillon effectives par module.

Module	N	Description
R1 / R1b	145 096	diversité mensuelle, tous combats
R2bis	145 096	BT mensuel style-controlled
R3	100 / 75	contrefactuels (Mistral seul / ensemble 2 juges)
R5	79 073	combats avec labels qualité
R5bis	79 073	idem + longueur
R6	89 modèles	tiers depuis ratings Zilinskas

3 Méthodes

3.1 R1 — Diversité stylistique temporelle

3.1.1 Indicateur de diversité

Pour chaque mois t , on calcule le centroïde stylistique de chaque modèle i : $\bar{\mathbf{f}}_{i,t} = \mathbb{E}[f(r) \mid \text{modèle } i, \text{ mois } t]$. La diversité du mois est la distance moyenne pairwise entre centroïdes actifs :

$$D_t = \frac{2}{M_t(M_t - 1)} \sum_{i < j} \|\bar{\mathbf{f}}_{i,t} - \bar{\mathbf{f}}_{j,t}\|_2. \quad (2)$$

Une **baisse** de D_t signalerait une convergence stylistique (symptôme Goodhart de stade 1). Nous testons aussi la distance de Wasserstein-2 entre distributions mensuelles de vecteurs stylistiques.

3.1.2 Régression temporelle

Régression OLS :

$$D_t = \alpha + \beta \cdot \text{month_idx}_t + \varepsilon_t, \quad (3)$$

où `month_idx` est l'index entier du mois depuis l'origine. $\beta < 0$ compatible avec convergence ; $\beta > 0$ avec diversification.

3.1.3 Robustesse (R1b)

Contrôles additionnels : nombre de modèles actifs par mois, volume de combats, effets fixes de mode d'arène.

3.2 R1-bis — Cohorte stable et artefact de composition

3.2.1 Motivation

Une hausse de D_t peut refléter l'entrée de modèles stylistiquement distincts (*artefact de composition*) plutôt qu'une divergence des modèles existants. R1-bis remesure la dispersion sur une **cohorte fixe**.

3.2.2 Périmètre et densification

Battles avec `source == "vote"`, ties exclus, timestamps valides ($< 1\%$ NaT). Features densifiées :

$$f^{\text{dens}} = \frac{f_{\text{brut}}}{\text{assistant_chars}} \quad (4)$$

(merge `votes_length.parquet` sur `conversation_pair_id`).

3.2.3 Cohorte stable

Modèles retenus si ≥ 100 battles totales et ≥ 12 mois distincts (fallback 10 mois si < 6 modèles ; non déclenché). Neuf modèles retenus, dont `llama-3.3-70b` et `llama-3.1-8b`.

3.2.4 Métrique commune

Distance euclidienne moyenne entre centroïdes (`method="centroid"`, identique à R1), z-score global, ≥ 100 réponses/modèle/mois, skip si < 5 modèles. Pour chaque mois t :

$$D_t^{\text{glob}} = \text{mean_pdist}(\text{centroïdes de tous modèles actifs}), \quad (5)$$

$$D_t^{\text{coh}} = \text{mean_pdist}(\text{centroïdes} \in \text{cohorte stable}). \quad (6)$$

3.3 R2bis — Style premium longitudinal

3.3.1 Modèle BT mensuel

Chaque mois t , on estime (1) par maximum de vraisemblance sur les combats du mois (ties exclus ou modélisés selon variante). Le coefficient $\gamma_{f,t}$ mesure le *style premium* de la feature f au mois t .

3.3.2 Interprétation en odds

$$\text{Premium}_f(\%) = (e^{\gamma_f} - 1) \times 100. \quad (7)$$

Un premium de +20 % signifie : si A a un écart-type de gras de plus que B , ses odds de victoire augmentent d'environ 20 %.

3.3.3 Tendance temporelle

Régression de $\gamma_{f,t}$ (ou Premium_f) sur `month_idx` pour tester si le marché *récompense de plus en plus* le formatage (stade 2 Goodhart).

3.4 R3 — Contrefactuels causaux

3.4.1 Protocole

Pour isoler l'effet *causal* du formatage, nous sélectionnons des réponses neutres (peu de markdown), puis les réécrivons selon deux traitements :

- **Concise_direct** : réponse courte, sans structure markdown ;
- **Verbose_markdown** : réponse longue, listes, gras, en-têtes.

Le contenu sémantique est préservé au maximum ; seul le format change.

3.4.2 Juges LLM

Deux juges évaluent chaque triplet (prompt, réponse A, réponse B) :

- **Mistral Large** (API Mistral) ;
- **Llama-3.3-70B** (API Groq).

3.4.3 Filtre de similarité sémantique

Pour éviter que le juge tranche sur un changement de contenu, nous exigeons $\cos(\text{emb}_A, \text{emb}_B) \geq 0,85$ (embeddings sentence-transformers).

3.4.4 Statistiques

Taux de victoire du traitement avec intervalle de confiance de Wilson [Wilson, 1927] à 95 %. Accord inter-juges : Cohen's κ [Cohen, 1960] et taux de victoire sur les paires où les deux juges sont valides et d'accord sur la comparaison.

L'effet causal estimé (ATE) pour le traitement $T \in \{\text{concise}, \text{verbose}\}$:

$$\widehat{\text{ATE}}_T = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[\text{juge préfère } T^{(i)}]. \quad (8)$$

3.5 R5 — Style *vs.* qualité déclarée

3.5.1 Modèle logistique

Sur les combats avec attributs qualité, outcome binaire $y_i = 1$ si A gagne :

$$\log \frac{p_i}{1 - p_i} = \beta_0 + \beta_q Q_i + \sum_f \beta_f \Delta f_i + \varepsilon_i, \quad (9)$$

où Q_i est le différentiel de score qualité agrégé.

3.5.2 Ablations et AUC

Nous comparons l'AUC in-sample de plusieurs spécifications : qualité seule, style seul, qualité+style, avec interactions temporelles. L'**incrément** Δ AUC mesure le gain prédictif du style *après* contrôle de la qualité déclarée.

3.5.3 Coefficients marginaux

Les odds ratios par feature : $OR_f = e^{\beta_f}$, interprétés comme en (7).

3.6 R5bis — Structure *vs.* longueur

R5bis étend (9) :

$$\log \frac{p_i}{1 - p_i} = \beta_0 + \beta_q Q_i + \beta_l \Delta \log(1 + |r|)_i + \sum_f \beta_f \Delta f_i. \quad (10)$$

Objectif : vérifier si le premium de structure (gras, listes...) persiste une fois la longueur contrôlée — réconciliant R3 (effet massif du format) et R5 (qualité domine en AUC).

3.7 R6 — Endogénéité par tier

3.7.1 Construction des tiers

Les modèles sont stratifiés en quartiles selon le rating Bradley-Terry de Zilinskas (JSON de ratings style-controlled).

3.7.2 Statistiques

- Corrélation de Pearson r entre rating et score de format moyen ;
- Différence de premium gras entre top et bottom tier ;
- Régression avec interaction $\gamma_f \times \text{tier}$.

Si seuls les modèles faibles *gameaient* le formatage, on s'attendrait à un premium concentré en bas de classement. L'hypothèse alternative (modèles forts mieux formatés *et* sur-récompensés) prédit $r > 0$ et premium croissant avec le tier.

4 Résultats

4.1 R1 — Diversité globale et artefact de composition

4.1.1 R1 brut

La diversité D_t (comptes bruts) **augmente** (Figure 1) : $\hat{\beta} = +0,057$ par mois, $p < 0,001$. Corrélation forte avec `n_models` ($r = 0,83$) : l'expansion du parc ($14 \rightarrow 43$ modèles) explique en partie la courbe.




FIGURE 1 – Diversité stylistique mensuelle (R1 brut, comptes bruts).

4.1.2 R1-bis — cohorte stable

Sur 79 075 battles votées (features **densifiées**), fenêtre fév.2025 – janv.2026 (12 mois), cohorte de **9 modèles** (Table 3).

TABLE 3 – Cohorte stable R1-bis (≥ 100 battles, ≥ 12 mois).

Modèle	Battles	Mois actifs
llama-3.1-405b	5 760	13
llama-3.1-8b	5 201	15
ministral-8b-instruct-2410	4 790	12
phi-4	4 524	12
llama-3.3-70b	4 468	13
gemma-3-4b	4 287	12
gemma-3-27b	3 807	12
gemma-3-12b	3 690	12
command-a	3 428	12




FIGURE 2 – R1-bis : dispersion globale vs cohorte stable (features densifiées). Annotations = `n_models_cohorte`.

OLS sur `month_idx` (Table 4) :

TABLE 4 – R1-bis : régressions OLS ($N = 12$ mois).

Série	Pente	IC 95 %	p	R^2
Dispersion globale	+0,038	[+0,015, +0,062]	0,005	0,567
Dispersion cohorte	−0,003	[−0,022, +0,016]	0,71	0,015

Lecture. Globalement, la dispersion *densifiée* monte encore (nouveaux modèles chaque mois). Sur la cohorte fixe, la pente est nulle : **pas de convergence** ni de divergence stylistique intra-cohorte. Le stade 1 Goodhart (convergence vers un format unique) n’est pas observé ; la hausse R1 globale est largement un *artefact de composition*.

4.2 R2bis — Premium élevé mais stable dans le temps

En niveau, le style premium est **fort** et cohérent avec Zilinskas : le gras vaut environ +20 % d’odds par écart-type (Figure 3).

En revanche, la pente temporelle du premium gras est **négative** : $\hat{\beta} = -1,4$ points de premium par mois — le formatage ne gagne *pas* en influence relative au fil des mois.




FIGURE 3 – Évolution mensuelle du style premium (R2bis). Niveau élevé, pente non positive.

Interprétation. Vulnérabilité structurelle au style (niveau), sans dérive temporelle du type stade 2 Goodhart.

4.3 R3 — Preuve causale

Table 5 et Figure 4 résument les contrefactuels.

TABLE 5 – Résultats contrefactuels (R3). IC 95 % Wilson.

Comparaison	N	Mistral	Llama-70B	Accord 2/2	IC accord
Concise vs neutre	45	88,9 %	90,9 %	97,3 %	[86, 100]
Verbose vs neutre	30	26,7 %	33,3 %	26,9 %	[14, 46]




FIGURE 4 – Taux de victoire par traitement et juge (R3). $\kappa(\text{Mistral}, \text{Llama-70B}) = 0,67$.

Changer *uniquement* le format suffit à inverser massivement les préférences : concis bat neutre dans $\approx 90\text{--}97\%$ des cas ; verbose *perd* contre neutre ($\approx 27\%$). L'accord inter-juges est substantiel ($\kappa = 0,67$).

Limites. Juges LLM, non utilisateurs Compar :IA ; N modeste mais effets très grands.

4.4 R5 — Le style ajoute de l'AUC au-delà de la qualité

Table 6 : ablation AUC in-sample sur 79 073 combats.

TABLE 6 – AUC in-sample par spécification logistique (R5).

Spécification	AUC	d features
Style seul (agrégé)	0,667	1
Style seul (composantes)	0,669	5
Qualité seule (agrégé)	0,811	1
Qualité seule (composantes)	0,821	7
Qualité + style (agrégé)	0,858	2
Qualité + style (composantes)	0,862	12
Qualité + style + interactions mois	0,863	17

La qualité déclarée domine ($\text{AUC}_q = 0,821$), mais le style apporte $+0,041$ AUC. Après contrôle qualité, le gras conserve $\approx +30,6\%$ d'odds de victoire (Figure 5).




FIGURE 5 – Coefficients style marginaux après contrôle qualité (R5).

4.5 R5bis — Structure vs longueur

Une fois qualité *et* $\Delta \log(1 + |r|)$ contrôlés (Table 7) :

TABLE 7 – R5bis : ablation structure vs longueur ($N = 79\,073$).

Spécification	AUC	Premium gras résiduel
Qualité + longueur	0,865	—
Qualité + longueur + style	0,865	+14,5 %

La longueur explique une partie de l'effet $\Delta \log(1 + |r|)$ de R3 (+40,5 % odds pour $\Delta \log(1 + |r|)$), mais le gras conserve un premium de +14,5 %. R3 et R5 se réconcilient : format *et* longueur opèrent, qualité reste le prédicteur dominant en AUC.




FIGURE 6 – Décomposition structure vs longueur (R5bis).

4.6 R6 — Les tops formatent plus (pas un gaming des faibles)

- $r(\text{rating}, \text{format score}) = 0,57$;
- premium gras : bottom tier vs top tier = +41,6 points ;
- les modèles bien classés produisent *plus* de markdown, et en bénéficient davantage.




FIGURE 7 – Style premium et formatage moyen par tier de rating (R6).

Interprétation. L’endogénéité est *symétrique* : le biais de formatage n’est pas l’apanage des modèles faibles tentant de compenser ; il touche aussi les leaders dont le style est à la fois plus riche et mieux récompensé.

4.7 Synthèse des modules

TABLE 8 – Cartographie des résultats et lien avec Goodhart.

Module	Question	Résultat	Stade Goodhart
R1	Convergence globale ?	Brut ↑ ; cohorte stable $\approx$ flat	Stade 1 : non
R1-bis	Artefact composition ?	Globale +0,038* ; cohorte −0,003 n.s.	Composition
R2bis	Premium ↑ dans le temps ?	Niveau haut, pente ≤ 0	Stade 2 : non
R3	Format cause-t-il le vote ?	Oui (large ATE)	Vulnérabilité
R5/R5bis	Au-delà qualité+longueur ?	Oui (+14–31 % gras)	Vulnérabilité
R6	Gaming des faibles ?	Non ($r = 0,57$)	Nuance
R4	Effondrement imminent ?	Abandonné	—

5 Discussion

5.1 Ce que nous apprenons sur Compar :IA

Trois messages pour les responsables de la plateforme :

1. **Pas de convergence intra-cohorte** (R1-bis) : sur 9 modèles stables, la dispersion densifiée est plate ($p = 0,71$) ; la hausse globale R1 reflète surtout l’élargissement du parc.
2. **Vulnérabilité réelle** : formatage et longueur influencent les votes causalement et prédictivement, même contrôlant la qualité déclarée.
3. **Biais structurel** : les modèles en tête de classement sont aussi ceux qui formatent le plus ; un simple contrôle style ne suffit pas à corriger le classement sans modèle causal plus fin.

5.2 Structure vs longueur

R3 montrait un contraste concis/verbose extrême ; R5 montrait la domination de la qualité en AUC. R5bis montre que ces résultats ne se contredisent pas : la longueur est un médiateur majeur, mais la structure markdown conserve un effet propre — exactement le pattern rapporté par LMSYS Style Control sur données anglaises [Li et al., 2024].

5.3 Qualité déclarée comme confondant

Les labels qualité sont *post-vote* et corrélés à la préférence. R5 contrôle ce biais observable ; il ne capture pas la qualité non déclarée. L’AUC de 0,862 reste in-sample ; une validation croisée temporelle serait nécessaire pour une généralisation out-of-sample.

5.4 Recommandations

1. Publier des classements *style-controlled* aux côtés des classements bruts (suivre Zilinskas) ;
2. Randomiser ou normaliser la longueur dans une fraction des combats ;
3. Monitorer D_t *global et cohorte stable* et $\gamma_{f,t}$ mensuellement ;
4. Compléter les juges LLM (R3) par des contrefactuels annotés par utilisateurs réels.

6 Limites

- **Labels qualité post-hoc** (R5) : biais de cohérence avec le vote.
- **AUC in-sample** : optimisme possible ; pas de split temporel strict.
- **R3 juges LLM** : externalité limitée vers votes humains Compar :IA.
- **Longueur en caractères** (R5bis) : pas en tokens ; corrélation forte mais imparfaite avec la facturation API.
- **Tiers R6** : ratings importés du snapshot Zilinskas, non ré-estimés mensuellement.
- **Causalité R3** : réécritures automatiques ; filtre cosine $\geq 0,85$ arbitraire.
- **16 mois** : fenêtre courte pour des phénomènes Goodhart lents [Espeland and Sauder, 2016].
- **R1-bis** : échelle densifiée $\neq$ R1 historique (comptes bruts) ; fenêtre 12 mois (2025-02 – 2026-01) ; cohorte $n = 9$.

7 Conclusion

Ce travail prolonge l’audit de Zilinskas [2026] sur *Compar :IA* selon une grille temporelle, causale et structurelle inspirée de la loi de Goodhart. Les données **ne montrent pas** une convergence stylistique sur une cohorte fixe (R1-bis) ni une dérive temporelle du style premium (R2bis) ; elles **montrent** une sensibilité persistante au formatage — causalement (R3), prédictivement (R5/R5bis) et corrélée au rang (R6).

Pour la gouvernance des benchmarks LLM, la leçon est proactive : un classement peut rester stable en corrélation ($r = 0,976$ chez Zilinskas) tout en restant gameable sur la marge. *Compar :IA* n’a pas encore ni mordu sa queue z, mais l’arène récompense déjà des proxys de surface — il est temps de construire des garde-fous avant qu’une cible explicite ne transforme ces vulnérabilités en stratégie d’optimisation.

Remerciements

Nous remercions Simon Zilinskas pour son travail préalable, le partage de code et de données, ainsi que l’équipe Compar :IA/DINUM pour la mise à disposition des jeux de données ouverts.

Références

- Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate : A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society Series B : Statistical Methodology*, 57(1) :289–300, 1995.
- Ralph A. Bradley and Milton E. Terry. Rank analysis of incomplete block designs : I. the method of paired comparisons. *Biometrika*, 39(3/4) :324–345, 1952.
- Wei-Lin Chiang, Lianmin Zheng, Ying Sheng, et al. Chatbot arena : An open platform for evaluating LLMs by human preference. In *ICML*, 2024.
- Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1) :37–46, 1960.
- Wendy Nelson Espeland and Michael Sauder. *Engines of Anxiety : Academic Rankings, Reputation, and Accountability*. Russell Sage Foundation, 2016.
- Charles A. E. Goodhart. Problems of monetary management : The U.K. experience. *Papers in Monetary Economics*, 1975.
- Tianle Li, Wei-Lin Chiang, et al. From crowdsourced data to high-quality benchmarks : Arena hard and benchbuilder pipeline. *arXiv preprint arXiv :2406.11939*, 2024.
- David Manheim and Scott Garrabrant. Categorizing variants of goodhart’s law, 2018.
- Lucie Termignon et al. compar :IA : The french government’s LLM arena to collect french-language human prompts and preference data. DINUM, Ministère de la Culture, 2026.
- Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158) :209–212, 1927.
- Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, et al. Judging LLM-as-a-judge with MT-Bench and chatbot arena. *Advances in Neural Information Processing Systems*, 36 :46595–46623, 2023.
- Simonas Zilinskas. Formatting bias in French LLM evaluation : Evidence from the Compar :IA arena. Working paper. Code : <https://github.com/simonaszilinskas/style-control-analysis>, 2026.

A Formules complémentaires

A.1 Intervalle de Wilson

Pour k succès sur n essais, avec $z = 1,96$:

$$\tilde{p} = \frac{k + z^2/2}{n + z^2}, \quad (11)$$

$$\text{IC}_{95\%} = \tilde{p} \pm \frac{z}{n + z^2} \sqrt{\frac{k(n - k)}{n} + \frac{z^2}{4}}. \quad (12)$$

A.2 Cohen’s κ

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \quad (13)$$

où p_o est l’accord observé et p_e l’accord attendu par indépendance.

A.3 Distance de Wasserstein (R1)

Pour deux distributions empiriques $\hat{\mu}_t, \hat{\mu}_{t+1}$ sur les vecteurs stylistiques :

$$W_2(\hat{\mu}_t, \hat{\mu}_{t+1}) = \left(\inf_{\gamma \in \Gamma} \mathbb{E}_{(x,y) \sim \gamma} \|x - y\|_2^2 \right)^{1/2}. \quad (14)$$

B Reproduction des résultats

Scripts principaux (répertoire scripts/) :

- `r1_robustness.py`, `r1bis_cohorte_stable.py`, `r2bis_style_premium.py`
- `r3_ensemble_judge.py`, `r5_style_vs_quality.py`
- `r5bis_structure_vs_length.py`, `r6_endogeneity_tiers.py`

Données : `data/raw/hf/comparia-votes/votes.parquet`. Figures : `paper/figures/`. Tables : `paper/tables/`.